# DADOS COMO ATIVO ESTRATÉGICO NA SAÚDE PÚBLICA: ANÁLISE DE GOVERNANÇA E QUALIDADE DO INDICADOR NEONATAL CRIB

**Autora: Paula Parreiras de Aquino**

## 1. INTRODUÇÃO

A qualidade, padronização e disponibilidade dos dados são elementos essenciais para que indicadores de saúde pública possam ser utilizados de forma confiável na formulação, monitoramento e avaliação de políticas públicas.

> *"Governança de dados, para a administração pública brasileira, refere-se a um conjunto de princípios, políticas, padrões, métricas e responsabilidades que permitem o alinhamento da estratégia, processos, pessoas, uso de tecnologia e dados. Assim, visa estruturar e administrar os ativos de dados com o objetivo de fomentar, aprimorar e garantir a efetividade do uso dos dados para o desenvolvimento de políticas públicas e entrega de soluções e serviços ao cidadão."*
>
> **Fonte: Cartilha de Governança de Dados do Poder Executivo Federal, disponível em: https://www.gov.br/governodigital/pt-br/infraestrutura-nacional-de-dados/governancadedados/forum-governanca-de-dados/cartilha-de-governanca-de-dados-volume1-8-12.pdf**

Sob essa perspectiva, este relatório apresenta uma avaliação exploratória de qualidade, documentação e governança do conjunto de dados público do indicador neonatal CRIB disponibilizado no Portal de Dados Abertos de Minas Gerais, com o objetivo de mapear oportunidades de fortalecimento do uso dos dados como ativo estratégico.

## 2. SOBRE A AUTORA

Engenheira de Produção (UFMG), com 15 anos de experiência em ambiente corporativo orientado por dados, atuando em áreas relacionadas à qualidade, normatização, processos e melhoria contínua. Ao longo da carreira, conduziu análises de dados e liderou projetos estratégicos e equipes multifuncionais.

A combinação dessa experiência profissional com ações voluntárias — como o ensino de inglês básico e a atuação em grupos voltados à promoção de diversidade e inclusão —, aliada à vivência da maternidade, reforçou o interesse em direcionar sua atuação para iniciativas com maior impacto social.

Nessa trajetória, aprofunda sua atuação na área de governança e estratégia de dados, com o propósito de contribuir com o fortalecimento da cultura do uso de informações para moldar políticas públicas e colaborar com projetos em contextos internacionais.

## 3. RESUMO EXECUTIVO

Este relatório apresenta uma análise exploratória de governança, qualidade e estratégia de dados do conjunto público do indicador neonatal CRIB disponibilizado no Portal de Dados Abertos de Minas Gerais. A avaliação identificou oportunidades de melhoria relacionadas à documentação de metadados, padronização de variáveis, consistência e completude dos dados. O estudo também discute o potencial analítico do conjunto de dados e sua possível integração com outras bases do sistema de saúde, destacando a importância da governança de dados para fortalecer o uso de evidências em ações governamentais. A Tabela 1 abaixo contempla o resultado sumarizado da avaliação detalhada ao longo desse relatório.

**Tabela 1: Avaliação de dimensões de qualidade e governança de dados**

| Dimensão | Nível | Principais Achados |
|---|---|---|
| Completude | Parcial | Lacunas temporais em determinadas unidades hospitalares |
| Exclusividade | Adequado | Não identificados registros duplicados |
| Consistência | Parcial | Inconsistências lógicas e de domínio |
| Padronização | Parcial | Divergências de tipagem e formatação entre períodos |
| Metadados | Parcial | Documentação e informações metodológicas limitadas |

## 4. DESCRIÇÃO DO CONJUNTO DE DADOS

O conjunto de dados analisado refere-se ao indicador neonatal CRIB, definido pelo próprio site do Governo de Minas Gerais como:

> *"Clinical Risk Index for Babies (CRIB) é um score que mensura o risco da mortalidade hospitalar de Recém Nato prematuro (RNPT) com peso ao nascer menor ou igual a 1500g ou Idade Gestacional menor que 31 semanas baseado na gravidade clínica inicial deste Recém Nato."*

O CRIB é um escore clínico amplamente utilizado para estimar a gravidade do estado de recém-nascidos nas primeiras horas de vida, considerando variáveis fisiológicas e clínicas.

A base disponibilizada no Portal de Dados Abertos de Minas Gerais apresenta registros agregados por unidade hospitalar, mês e categoria de risco, contemplando variáveis relacionadas ao volume de saídas de recém-nascidos, predição de óbito associada ao escore, óbitos esperados segundo o modelo e óbitos efetivamente observados. A série temporal vai de 2018 a 2025 e os arquivos estão disponíveis em: https://dados.mg.gov.br/dataset/crib

## 5. METODOLOGIA

Os dados de cada série anual foram extraídos manualmente do portal oficial de dados abertos do Estado de Minas Gerais, por meio do download dos arquivos em formato CSV correspondentes ao período de 2018 a 2025.

Após a extração, os arquivos anuais foram consolidados em tabela única estruturada em um banco de dados, com definição prévia de schema padronizado, garantindo uniformidade de nomes de variáveis, tipagem de dados e integridade histórica.

O processo de consolidação envolveu:

a. Padronização de campos entre diferentes anos;

b. Definição e aplicação de tipos de dados consistentes (ex.: campos quantitativos como inteiros);

c. Identificação de inconsistências estruturais e recomendações de melhoria;

d. Validação de compatibilidade entre variáveis correlatas;

e. Execução de consultas SQL para verificação de integridade e consistência dos registros.

A análise concentrou-se na avaliação exploratória de qualidade, documentação e governança, com foco nas dimensões de completude, consistência, padronização, integridade estrutural e disponibilidade de metadados.

# 6. PRINCIPAIS ACHADOS

## 6.1. Avaliação de Metadados & Documentação

Os metadados, ou "dados sobre dados" são essenciais para compreender o que aqueles dados significam, seu escopo e abrangência. Portanto definições claras e explícitas se fazem necessárias para possibilitar a interpretação correta da base de dados e, consequentemente, uma tomada de decisões baseada em evidências reais.

### 6.1.1. Achado 01: Acessibilidade e unicidade do dicionário de dados

Descrição: Ausência do dicionário de dados na página principal do indicador

Evidências: O portal disponibiliza um dicionário de dados com descrição das colunas, porém essa informação está localizada na página individual de cada ano e não na página principal do conjunto de dados.

Impacto: A baixa visibilidade da documentação reduz a compreensão inicial da estrutura da base e dificulta seu uso por usuários, analistas e pesquisadores. A redundância, por sua vez, reduz a eficiência operacional e gera riscos de divergência entre bases.

Recomendação: Recomenda-se disponibilizar o dicionário de dados de forma mais visível na página principal do conjunto de dados ou em documentação consolidada.

### 6.1.2. Achado 02: Definição de variáveis

Descrição: Ausência de definição explícita para cada variável

Evidências: O dicionário de dados apresenta uma tabela com o nome da coluna (variável), tipo, rótulo e descrição, no entanto todas as variáveis estão classificadas como tipo "texto" e as descrições não apresentam definições claras e detalhadas, conforme algumas evidências que seguem:

i. O campo `unidade` está descrito como "Sigla da Unidade Hospitalar" porém não consta quais unidades estão sendo avaliadas, o que pode ser deduzido pelos dados. Além disso, a definição de cada sigla não é explicitada;

ii. O campo `saidas_rn` é descrito apenas como "quantidade de saídas de recém-nascidos", sem especificação sobre se o termo inclui ou exclui óbitos.

Impacto: A ausência de definição explícita no dicionário de dados pode gerar interpretações divergentes pelos usuários, representando uma limitação de metadados e potencial risco de interpretação equivocada nas análises.

Recomendação:

i. Revisitar as variáveis para definir tipos corretos para cada uma delas
ii. Detalhar as descrições das variáveis, de forma a incluir conceitos claros e referências.

### 6.1.3. Achado 03: Definição de metadados

Descrição: Falta de definição clara de metadados para a variável `obitos_esperados`

Evidências: Observou-se que a variável `obitos_esperados` aparenta relação com a taxa de `predicao_obito` e com o volume de `saidas_rn`, sugerindo tratar-se de indicador derivado. Contudo, o método de cálculo não está explicitado na documentação ou no dicionário de dados disponibilizado, impossibilitando a confirmação exata do indicador a partir das variáveis presentes na base.

Impacto: A ausência de documentação sobre o método de cálculo da variável `obitos_esperados` compromete a reprodutibilidade das análises e dificulta a verificação independente dos resultados. Além disso, a relação analítica entre `predicao_obito`, `obitos_esperados` e `obitos_ocorridos`, que permite comparar mortalidade observada e prevista pelo modelo CRIB, não está explicitada na documentação da base, limitando seu uso analítico.

Recomendação:

i. Incluir no dicionário de dados ou documentação da base a descrição do método de cálculo de `obitos_esperados`;

ii. Explicitar a relação analítica entre `predicao_obito`, `obitos_esperados` e `obitos_ocorridos`.

## 6.2. Avaliação de Qualidade dos Dados

A qualidade dos dados é um dos pilares fundamentais da governança de dados, pois inconsistências, lacunas ou divergências estruturais podem comprometer análises, confiabilidade de indicadores e decisões que afetam diretrizes estatais.

### 6.2.1. Achado 04: Consistência lógica

Descrição: Inconsistência lógica entre valores das variáveis `saidas_rn` e `obitos_ocorridos`

Evidências: Ao aplicar a regra de consistência `obitos_ocorridos` ≤ `saidas_rn`, foi identificado registro em que o número de óbitos ocorridos (`obitos_ocorridos` = 2) é superior ao número de saídas de recém-nascidos (`saidas_rn` = 1), na unidade `MOV`, mês `07/2022`. Considerando que o conceito de "saída" em registros hospitalares geralmente corresponde ao encerramento da internação (incluindo alta, transferência ou óbito), espera-se que o número de óbitos seja sempre menor ou igual ao número total de saídas.

Impacto: Esse tipo de inconsistência compromete a coerência lógica do dataset e pode gerar distorções em análises de mortalidade, especialmente em cálculos de taxa ou razão de óbitos observados em relação às saídas registradas.

Recomendação: Recomenda-se:

i. Validação do registro junto à base original ou à equipe responsável pela consolidação dos dados;

ii. Implementação de regras automáticas de validação que impeçam o registro de valores de `obitos_ocorridos` superiores a `saidas_rn`.

### 6.2.2. Achado 05: Consistência de domínio

Descrição: Inconsistência de domínio da variável `escore`

Evidências: Foi identificada inconsistência no registro do escore grau `III` descrito como `11 a 5`, contendo:

i. inconsistência na delimitação do intervalo numérico, incompatível com a lógica sequencial das demais faixas e com as variáveis associadas. Observa-se que a variável `grau` apresenta valor `III`, usualmente correspondente à faixa `11 a 15`, e que a variável `predicao_obito` atribui o mesmo valor (`73,1`) tanto para `11 a 5` quanto para `11 a 15`, indicando possível erro de digitação na descrição do intervalo;

ii. inconsistência de padronização textual, com espaço excedente ao fim, mesma divergência detectada para a faixa de `11 a 15 `

Impacto: A inconsistência pode gerar erro na categorização do indicador e comprometer a interpretação adequada dos dados, especialmente em análises automatizadas ou comparativas.

Recomendação:

i. Validação junto à equipe responsável pela coleta, manutenção da base para confirmação do intervalo correto e posterior correção no banco de dados;

ii. Estabelecer intervalos de escore como opções pré-definidas e selecionáveis nos sistemas de entrada de dados, reduzindo risco de erro manual e aumentando a consistência das informações.

### 6.2.3. Achado 06: Completude de série temporal

Descrição: Lacunas de registros na série temporal

Evidências:

i. Ausência da base de dados correspondente ao ano de 2024 no conjunto disponibilizado. Adicionalmente, o arquivo denominado "CRIB 2025" apresenta descrição como "CRIB - Clinical Risk Index for Babies 2024", embora contenha registros referentes ao ano de 2025;
ii. Ausência de registros em determinados meses para algumas unidades hospitalares no ano de 2018. Considerando que os dados são apresentados com periodicidade mensal para cada unidade hospitalar, espera-se a existência de registros para todos os meses do ano. Registros faltantes: 1) Unidade HJK, meses de fevereiro a dezembro de 2018; 2) Unidade HRAD, para o mês de julho de 2018;
iii. Ausência de registro para a unidade `HRJP`, no período de abril de 2020, referente ao grau `II`.

Impacto: Lacunas na série temporal podem comprometer análises comparativas ao longo do tempo e dificultar a correta interpretação de tendências ou variações entre unidades hospitalares.

Recomendação:

i. Avaliar a origem das lacunas identificadas e complementar a base de dados atual;
ii. Quando aplicável, incorporar mecanismos de validação ou documentação que permitam distinguir ausência de registro de valor zero.

### 6.2.4. Achado 07: Padronização e tipagem de variável

Descrição: Padronização e tipagem inconsistentes no campo `saidas_rn`, base 2019

Evidências: Identificada inconsistência na base de 2019 no campo `saidas_rn`. O campo representa a quantidade de saídas de recém-nascidos, caracterizando valor discreto e não fracionado, e portanto deveria estar definido como número inteiro. Entretanto, na base de 2019 os registros apresentam valores com casa decimal (ex.: `4,0`), divergindo do padrão adotado nos demais anos.

Impacto: A inconsistência compromete a padronização do conjunto de dados e pode gerar erros em análises automatizadas, agregações e modelagens estatísticas. Não foi possível determinar, a partir da base disponibilizada, a origem da inconsistência.

Recomendação: Recomenda-se revisão do campo `saidas_rn` na base referente ao ano de 2019, com ajuste de tipagem para valor inteiro, garantindo padronização e consistência com os demais anos.

### 6.2.5. Achado 08: Tipagem de variável

Descrição: Tipagem inadequada do campo `mes`, como texto ao invés de número

Evidências: O campo `mes` está armazenado como texto, o que gera problemas de codificação e dificulta comparações. Em adição, o caractere "ç" em `março`, pode causar falhas em sistemas que não suportam acentuação ou caracteres especiais.

Impacto: Dificuldade em realizar comparações, ordenações e agrupamentos confiáveis e automatizados, principalmente em relação a bases internacionais.

Recomendação: Para garantir consistência e interoperabilidade, recomenda-se que o mês seja representado em formato numérico (1–12) ou como parte de uma data padronizada (YYYY-MM-DD).

## 7. O DADO COMO ATIVO ESTRATÉGICO: INTEROPERABILIDADE E POTENCIAL ANALÍTICO

Quando adequadamente governados, dados públicos podem funcionar como ativos estratégicos, permitindo que governos produzam evidências, aprimorem a formulação de políticas públicas e ampliem a efetividade dos serviços prestados à sociedade. Nesse contexto, a interoperabilidade — entendida como a capacidade de sistemas e organizações de trabalharem de forma integrada para compartilhar informações — é elemento central para ampliar o valor e o uso dos dados.

A análise realizada indica que o conjunto de dados do indicador neonatal CRIB possui potencial para apoiar avaliações relacionadas à mortalidade neonatal em unidades hospitalares, considerando a presença de variáveis associadas ao modelo clínico, como predição de óbito, óbitos esperados e óbitos observados. No entanto, limitações de consistência de registros, lacunas temporais e fragilidades na documentação de metadados podem restringir seu uso analítico e a comparabilidade entre períodos e instituições.

O aprimoramento da base, por meio da ampliação de metadados e da inclusão de identificadores padronizados das unidades hospitalares — como o código CNES ou informações de localização geográfica —, pode viabilizar a integração do indicador CRIB com outras bases do sistema de saúde brasileiro, como o SINASC e o SIM. Essa articulação amplia as possibilidades de análise sobre fatores associados à mortalidade neonatal e fortalece comparações entre unidades hospitalares e regiões.

Adicionalmente, a disponibilização de variáveis clínicas complementares — como peso ao nascer, idade gestacional ou características do parto — pode aprofundar a investigação sobre determinantes da mortalidade neonatal.

Por fim, destaca-se que o modelo CRIB permite não apenas estimar o risco de mortalidade, mas também avaliar o desempenho relativo entre unidades hospitalares por meio da relação entre óbitos observados e esperados, indicador amplamente utilizado em análises de qualidade assistencial. Nesse contexto, a confiabilidade, padronização e completude dos dados tornam-fundamentais, uma vez que inconsistências ou lacunas podem impactar diretamente a interpretação dos resultados.

A Figura 1 ilustra, de forma conceitual, como a integração do indicador CRIB com sistemas nacionais de informação em saúde pode ampliar as possibilidades analíticas no contexto da saúde pública.

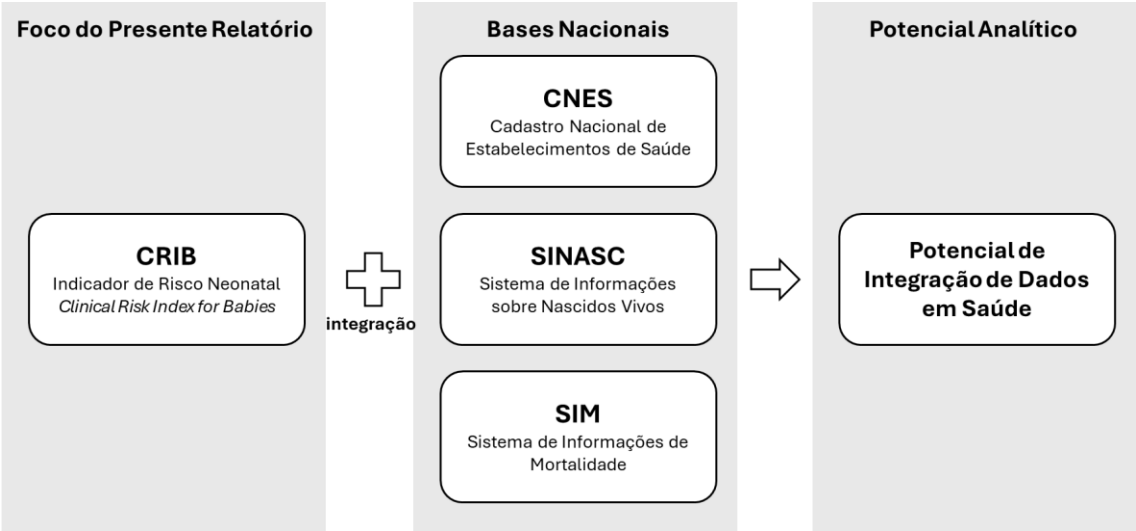


**Figura 1: Potencial de interoperabilidade entre indicador CRIB e bases nacionais de dados em saúde**

## 8. IMPLICAÇÕES PARA A GOVERNANÇA DE DADOS

A análise realizada permite observar como aspectos de governança de dados influenciam diretamente a confiabilidade e o potencial de uso de indicadores de saúde pública. Limitações observadas na documentação, padronização e consistência dos dados apontam oportunidades de fortalecimento de práticas de governança ao longo do ciclo de vida da informação, incluindo coleta, validação, consolidação e publicação dos dados.

Além dos aspectos técnicos e analíticos, a governança de dados envolve também a definição clara de responsabilidades institucionais sobre a produção, atualização, validação e publicação dos dados. A ausência de informações públicas sobre o processo de geração, validação e atualização do indicador pode limitar a transparência do ciclo de vida dos dados e dificultar sua avaliação por usuários externos.

## 9. CONCLUSÃO

Este estudo evidenciou que, embora o conjunto de dados do indicador CRIB apresente potencial relevante para apoiar análises sobre mortalidade neonatal, limitações relacionadas à padronização, documentação e consistência ainda restringem seu uso pleno como insumo para políticas públicas baseadas em evidências.

Os achados reforçam que a governança de dados não se limita à disponibilização de bases públicas, mas envolve a estruturação de processos, definições e responsabilidades que garantam qualidade, rastreabilidade e interoperabilidade ao longo de todo o ciclo de vida da informação.

O fortalecimento dessas práticas pode ampliar significativamente o valor analítico do indicador, viabilizando integrações com outras bases do sistema de saúde e apoiando avaliações mais robustas sobre a qualidade da assistência neonatal. Nesse contexto, a evolução da governança de dados se apresenta como um elemento-chave para transformar dados públicos em ativos efetivamente estratégicos para o setor de saúde.

## 10. RECOMENDAÇÕES PARA FORTALECIMENTO DA GOVERNANÇA E QUALIDADE

As recomendações a seguir foram estruturadas com foco na melhoria incremental da qualidade, transparência e interoperabilidade do conjunto de dados, considerando sua viabilidade de implementação no contexto da administração pública:

### 10.1. Recomendação 01: Padronização e publicação do dicionário de dados

Ação Proposta: Padronizar e disponibilizar um dicionário de dados único e completo, contendo definição de variáveis, tipagem, domínio de valores e regras de cálculo para variáveis derivadas

Responsável Sugerido: Equipe gestora do indicador / Área de dados da Secretaria de Saúde

Priorização: Curto prazo

Impacto: Aumento da clareza do conjunto de dados, redução de ambiguidades, maior confiabilidade analítica e ampliação do uso por usuários externos.

### 10.2. Recomendação 02: Fortalecimento de regras de validação e consistência

Ação Proposta: Implementar validações automatizadas para garantir consistência e completude dos dados

Responsável sugerido: Equipe técnica de dados / TI

Priorização: Médio prazo

Impacto: Aumento da confiabilidade das análises e redução de retrabalho

### 10.3. Recomendação 03: Tratamento e monitoramento de lacunas temporais

Ação Proposta: Tratar lacunas existentes na base, identificar causas de ausência de registros e estabelecer processos de monitoramento contínuo da completude da base

Responsável Sugerido: Área responsável pela coleta e consolidação dos dados

Priorização: Médio prazo

Impacto: Garantia da completude da série temporal e aumento do potencial de comparação entre períodos e unidades

### 10.4. Recomendação 04: Inclusão de identificadores e variáveis clínicas

Ação Proposta: Incluir identificadores, como código CNES, atributos de localização geográfica das unidades hospitalares e variáveis clínicas adicionais relevantes para análises epidemiológicas e avaliação de qualidade assistencial (ex.: característica do parto, dados do recém-nascido, etc.)

Responsável Sugerido: Área responsável pela coleta e consolidação dos dados

Priorização: Médio prazo.

Impacto: Integração com sistemas como SINASC e SIM, permitindo análises mais abrangentes e comparações regionais/nacionais, ampliando a interoperabilidade

### 10.5. Recomendação 05: Estruturação e transparência do processo do indicador

Ação Proposta: Definir e disponibilizar informações sobre o fluxo de produção do indicador, incluindo origem dos dados, etapas de processamento, critérios de validação e periodicidade de atualização.

Responsável Sugerido: Área gestora do indicador / Governança de dados

Priorização: Curto prazo

Impacto: Aumento da transparência do ciclo de vida dos dados, melhoria da rastreabilidade das informações e fortalecimento da confiança dos usuários no indicador.

## 11. REFERÊNCIAS

Governo de Minas Gerais. Portal de Dados Abertos – Base CRIB. Disponível em: https://dados.mg.gov.br/dataset/crib

Brasil. Ministério da Gestão e Inovação. Cartilha de Governança de Dados do Poder Executivo Federal.